


# OBRADA INFORMACIJE

## IZVJEŠTAJ – 3. LABORATORIJSKA VJEŽBA

**IZVJEŠTAJ:** Skicirajte dijagram stanja za ovako opisan model.

**ODGOVOR:**



Slika 1. Dijagram stanja modela

### Pod-zadatak 1 - Cjelovito definiranje HMM modela u Matlabu

Temeljem zadanih ucestalosti pojedinih ishoda bacanja pristranih kocki i temeljem zadanog parametra  $M$  u vasem Moodle zadatku, potrebnoje dopuniti predlozak Matlab skripte kako bi cjelovito opisali zadani HMM model ovog eksperimenta ukljucujuci i matricu vjerojatnosti osmatranja izlaznih simbola.

*Isječak programskog koda korištenog za rješavanje pod-zadatka 1*

```
clear;
% Dodavanje puta na biblioteku funkcija
addpath(genpath('C:\Users\Matija Jakovac\Documents\MATLAB\HMMall'))

% Vektor inicijalne vjerojatnosti stanja

prior0=
```

```
1 % Prva kocka (ako je palo '1')
2 % Druga kocka (ako je palo '2' ili '3')
3 % Treća kocka (ako je palo '4', '5' ili '6')
]/6;

% Broj stanja HMM modela
Q=size(prior0,1);

M=9; % personalizirani M

% Matrica vjerojatnosti promjena stanja
%
% a11 a12 a13
% a21 a22 a23
% a31 a32 a33

% Formiranje matrice vjerojatnosti prijelaza stanja
% (uz cikličku strukturu izmjene stanja, jer su
% prijelazi 1->3, 2->1 i 3->2 zabranjeni)
transmat0 = [
M-1 1 0 % P(1|1) P(2|1) P(3|1)
0 M-1 1 % P(1|2) P(2|2) P(3|2)
1 0 M-1 % P(1|3) P(2|3) P(3|3)
]/M;

% Matrica emisijskih vjerojatnosti
% svaki redak odgovara jednom stanju, a
% svaki stupac jednoj mogućoj opservaciji
obsmat0 = [
20 3 1 6 4 6 % P(1|1. kocka) P(2|1. kocka) P(3|1. kocka) P(4|1. kocka) P(5|1.
kocka) P(6|1. kocka)
4 4 20 2 3 7 % P(1|2. kocka) P(2|2. kocka) P(3|2. kocka) P(4|2. kocka) P(5|2.
kocka) P(6|2. kocka)
2 5 5 6 20 2 % P(1|3. kocka) P(2|3. kocka) P(3|3. kocka) P(4|3. kocka) P(5|3.
kocka) P(6|3. kocka)
]/40;

% Ukupni broj simbola rječnika - u ovom slučaju 6 (1,2,3,4,5 ili 6 dobiveno na
kocki)
O=size(obsmat0, 2);
```

## Pod-zadatak 2 - Određjivanje log-izvjesnosti osmatranja zadanog izlaznog niza simbola za zadani model

Osmotrena su dva niza duljine  $T=41$  simbola kojeg je generirao model L:

$O = [o_1 \dots o_T] =$

```
[ 3 3 3 4 4 5 5 5 3 4 1 1 1 1 1 4 1 2 4 1 4 5 1 6 1 1 1 6 4 1 2 6 6 1 3 3 3 6 3 1 1]
[ 2 2 6 4 6 2 2 2 6 4 2 5 1 2 6 5 6 6 6 1 2 5 4 1 1 4 6 1 3 6 5 6 6 6 1 6 6 1 3 1 6]
```

(2a) [1 bod] Izračunajte log-izvjesnosti osmatranja ova dva niza uz zadane parametre HMM modela te ih upišite u naredna dva polja:

Log-izvjesnost osmatranja prvog niza: **-62.1181**

Log-izvjesnost osmatranja drugog niza: **-80.4309**

(2b) [1 bod] Izracunajte i upisite u Moodle koliko puta je drugi niz manje izvjestan od prvog u eksponencijalnom zapisu:

Drugi niz je **8.9780e+07** manje izvjestan nego li prvi.

*Isječak programskog koda korištenog za rješavanje pod-zadatka 2*

```
% Inicijalizacija podataka
data1 = [3 3 3 4 4 5 5 5 3 4 1 1 1 1 1 4 1 2 4 1 4 5 1 6 1 1 1 6 4 1 2 6 6 1 3 3 3
6 3 1 1;
        2 2 6 4 6 2 2 2 6 4 2 5 1 2 6 5 6 6 6 1 2 5 4 1 1 4 6 1 3 6 5 6 6 6 1 6 6
1 3 1 6];

% Pretvaranje matrice u ćelije, svaki red postaje zasebna ćelija
data1 = num2cell(data1, 2);

% Brojanje slučajeva (broj ćelija u data1)
ncases1 = length(data1);

% Inicijalizacija niza za zabilježavanje greški
errors = [];

% Petlja koja obrađuje pojedinačni niz
for m = 1:ncases1
    % Izračunavanje za prvi niz
    if m == 1
        % Matrica koja sadrži vjerojatnosti osmatranja prvog niza u
        % svim stanjima modela
        obslik1 = multinomial_prob(data1{m}, obsmat0);
        % Izračun matrice unaprijednih i unazadnih vjerojatnosti, pomoćne
        % vjerojatnosti gama za re-estimaciju HMM modela te logaritamske
        % izvjesnosti osmatranja niza
        [alpha1, beta1, gamma1, ll1] = ...
            fwdback(prior0, transmat0, obslik1, 'scaled', 0);
        fprintf('Log izvjesnost prvog niza je %f\n', ll1);
        if ll1 == -inf
            errors = [errors m];
        end
    % Izračunavanje za drugi niz
    elseif m == 2
        % Matrica koja sadrži vjerojatnosti osmatranja drugog niza u
        % svim stanjima modela
        obslik2 = multinomial_prob(data1{m}, obsmat0);
        % Izračun matrice unaprijednih i unazadnih vjerojatnosti, pomoćne
        % vjerojatnosti gama za re-estimaciju HMM modela te logaritamske
        % izvjesnosti osmatranja niza
        [alpha2, beta2, gamma2, ll2] = ...
            fwdback(prior0, transmat0, obslik2, 'scaled', 0);
        fprintf('Log izvjesnost drugog niza je %f\n', ll2);
        if ll2 == -inf
            errors = [errors m];
        end
    end
end
end
```

```
% Sumiranje vrijednosti u matricama alpha1 i alpha2
% kako bi dobili ukupnu vjerojatnost osmatranja niza
alpha1_sum = sum(alpha1);
alpha2_sum = sum(alpha2);

% Izračunavanje i ispis koliko je drugi niz manje vjerojatan nego li prvi
% niz
difference = alpha1_sum(41) / alpha2_sum(41);
fprintf('Drugi niz je %e manje vjerojatan nego prvi\n', difference);

>> podzadatak2_jakovac
Log izvjesnost prvog niza je -62.118050
Log izvjesnost drugog niza je -80.430924
Drugi niz je 8.978011e+07 manje vjerojatan nego prvi
```

Slika 2. Rezultati izvršavanja priloženog koda za pod-zadatak 2

**IZVJEŠTAJ:** Možete li usporedbom zadanih nizova obrazložiti razlog zbog kojeg je drugi niz manje izvjestan od prvog? Opišite riječima.

**ODGOVOR:** Samom usporedbom i promatranje dvaju nizova možemo zaključiti da je drugi niz manje izvjestan po tome što su u prvom nizu puno više ponavljaju brojevi 1, 3 ili 5 koji su sami po sebi najvjerojatniji ishodi od svih brojeva. Naravno, to ovisi o koja je kocka bačena no uzevši i to u obzir vjerojatniji će biti niz koji ima više ponavljanja ovih triju brojeva i to zaredom.

### Pod-zadatak 3 - Izračunavanje vjerojatnosti unaprijed i unazad za sva skrivena stanja modela i sve vremenske trenutke osmatranja

(3a) [1 bod] Za prvu sekvencu iz pod-zadatka 2 potrebno je primijeniti algoritme "Unaprijed" i "Unazad" i izračunati unaprijedne vjerojatnosti i unazadne vjerojatnosti za sve trenutke osmatranja  $t=1 \dots T$  za zadani model  $L$ .

**Vazno:** pri pozivu funkcije ne smijete aktivirati skaliranje vjerojatnosti, tj. u pozivu funkcije morate definirati ..., 'scaled', 0); kao što je učinjeno u primjeru u uputama. Upisite koji iznos unaprijedne vjerojatnosti ste dobili za  $\alpha_t(1)$  za  $t=27$  u prvo polje, odnosno iznos unazadne vjerojatnosti za  $\beta_t(2)$  za  $t=12$  u drugo polje u eksponencijalnom zapisu.

$$\alpha_{27}(1) = \mathbf{1.4200e-17}$$

$$\beta_{12}(2) = \mathbf{2.4894e-22}$$

*Isječak programskog koda korištenog za rješavanje pod-zadatka 3*

```
% Prikaz unaprijedne vjerojatnosti za prvu sekvencu pomoću točnog elementa
% matrice odnosno vjerojatnosti da je u vremenskom trenutku 27 osmotreno
% stanje 1
fprintf('Alpha u vremenskom trenutku 27 za prvo stanje iznosi %e\n', alpha1(1,27))
```

```
% Prikaz unazadne vjerojatnosti za prvu sekvencu pomoću točnog elementa
% matrice odnosno vjerojatnosti da je u vremenskom trenutku 12 osmotreno
% stanje 2
fprintf('Beta u vremenskom trenutku 12 za drugo stanje iznosi %e\n', beta1(2,12))
>> podzadatak3_jakovac
Alpha u vremenskom trenutku 27 za prvo stanje iznosi 1.419991e-17
Beta u vremenskom trenutku 12 za drugo stanje iznosi 2.489377e-22
```

Slika 3. Rezultati izvršavanja priloženog koda za pod-zadatak 3

**IZVJEŠTAJ:** Obrazložite i prikažite kako možete iskoristiti vjerojatnosti alfa iz zadnjeg koraka u svrhu određivanja log-izvjesnosti osmatranja cijelog niza, odnosno kako možete iskoristiti izračunatu unazadnu vjerojatnost beta iz prvog vremenskog koraka u istu svrhu, te usporedite tako dobivene rezultate s onim iz pod-zadatka 2 za prvi osmotreni niz.

**ODGOVOR:** Vjerojatnosti alfa iz zadnjeg koraka možemo iskoristiti tako da sumiramo sve te vjerojatnosti po stupcu odnosno sumiramo vjerojatnost za svako stanje u zadnjem vremenskom trenutku te tako dobijemo ukupnu vjerojatnost osmatranja niza. Beta iz prvog vremenskog koraka možemo iskoristiti za istu svrhu određivanje ukupne vjerojatnosti tako da ju pomnožimo s vektorom inicijalne vjerojatnosti i vektorom izlaznih vjerojatnosti konkretnog osmotrenog simbola u prvom vremenskom koraku (simbola „3”). Sumiramo taj stupac beta vjerojatnosti te ćemo dobiti istu ukupno vjerojatnost osmatranja niza kao i preko alfe.

*Isječak koda kojim možemo provesti određenu usporedbu (kod je nastavak na prijašnji kod korišten u ovom pod-zadatku)*

```
fprintf('Ukupna vjerojatnost osmatranja prvog niza dobivena preko alfe %e\n',
alpha1_sum(41))

% Umnožak i sumacija prvog vremenskog koraka bete, vektora inicijalne
% matrice te vektor izlazne vjerojatnosti konkretnog osmotrenog simbola u
% prvom vremenskom koraku
beta_ukupna_vjerojatnost = sum(beta1(:,1).*prior0.*obslik1(:,1));
fprintf('Ukupna vjerojatnost osmatranja prvog niza dobivena preko bete %e\n',
beta_ukupna_vjerojatnost);

Ukupna vjerojatnost osmatranja prvog niza dobivena preko alfe 1.053110e-27
Ukupna vjerojatnost osmatranja prvog niza dobivena preko bete 1.053110e-27
```

Slika 4. Rezultati izvršavanja priloženog koda za pod-zadatak 3

#### Pod-zadatak 4 - Dekodiranje skrivenih stanja pomoću Viterbi algoritma

(4a) [1 bod] Potrebno je primjenom Viterbi algoritma odrediti najizvjesniji niz skrivenih stanja modela za prvi osmotreni niz iz drugog pod-zadatka. U narednih šest polja upišite dekodirana stanja modela za prva tri i za zadnja tri vremenska koraka prve opservacije:

Dekodirana stanja modela za prva tri i za zadnja tri vremenska koraka su **2,2,2,2,2,2**.

*Isječak programskog koda korištenog za rješavanje pod-zadatka 4*

```
% Iskorištavanje funkcije za izračun Viterbijevog puta za prvi niz
vpath1 = viterbi_path(prior0, transmat0, obslik1);
% Prikaz cijelog puta
disp(vpath1);
% Ispis određenih vrijednosti potrebnih za pod-zadatak
fprintf('Prvih tri i zadnji tri vremenska koraka Viterbijevog puta
%d,%d,%d,%d,%d,%d.\n', vpath1(1), vpath1(2), vpath1(3), vpath1(39), vpath1(40),
vpath1(41));
```

```
>> podzadatak4_jakovac
Columns 1 through 18

     2     2     2     3     3     3     3     3     3     1     1     1     1     1     1     1     1     1

Columns 19 through 36

     1     1     1     1     1     1     1     1     1     1     1     1     1     1     1     1     2     2

Columns 37 through 41

     2     2     2     2     2

Prvih tri i zadnji tri vremenska koraka Viterbijevog puta 2,2,2,2,2,2.
```

Slika 5. Rezultati izvršavanja priloženog koda za pod-zadatak 4

### Pod-zadatak 5 - Odredjivanje log-izvjesnosti osmatranja uzduz dekodiranih Viterbi puteva

(5a) [1 bod] Ponovite odredjivanje Viterbi niza stanja i za drugi osmotreni niz iz pod-zadatka 2, te za oba niza izracunajte log-izvjesnostiosmatranja ali samo uzduz dekodiranih ?optimalnih? Viterbi puteva. Usporedite dobivene rezultate s onima iz pod-zadatka 2 gdje jeizracunata ukupna log-izvjesnost za sve moguće puteve skrivenih stanja. U naredna dva polja upisite razliku log-izvjesnosti preko svih puteva i log-izvjesnosti uzduz Viterbi puta za oba osmotrena niza:

Razlika log-izvjesnosti preko svih puteva i log-izvjesnosti uzduz Viterbi puta za prvi niz: **2.651614**

Razlika log-izvjesnosti preko svih puteva i log-izvjesnosti uzduz Viterbi puta za drugi niz: **4.575125**

*Isječak programskog koda korištenog za rješavanje pod-zadatka 5*

```
% Iskorištavanje funkcije za izračun Viterbijevog puta za drugi niz
vpath2 = viterbi_path(prior0, transmat0, obslik2);

% Iskorištavanje funkcije za izračun log-vjerojatnosti za određeni put (u
% ovom primjeru to su Viterbijski putevi za prvi i drugi niz)
[l11_v, p1_v] = dhmm_logprob_path(prior0, transmat0, obslik1, vpath1);
[l12_v, p2_v] = dhmm_logprob_path(prior0, transmat0, obslik2, vpath2);
```

```
% Ispis log-izvjesnosti za Viterbi puteve
fprintf('Log-izvjesnost za Viterbi put prvog niza: %f\n', ll1_v);
fprintf('Log-izvjesnost za Viterbi put drugog niza: %f\n', ll2_v);

% Ispis razlike log izvjesnosti preko svih puteva i uzduz Viterbi puta za
% određeni niz
fprintf('Razlika log-izvjesnosti preko svih puteva i uzduz Viterbi puta za prvi
niz: %f\n', ...
        ll1-ll1_v);
fprintf('Razlika log-izvjesnosti preko svih puteva i uzduz Viterbi puta za drugi
niz: %f\n', ...
        ll2-ll2_v);

>> podzadatak5_jakovac
Log-izvjesnost za Viterbi put prvog niza: -64.769664
Log-izvjesnost za Viterbi put drugog niza: -85.006049
Razlika log-izvjesnosti preko svih puteva i uzduz Viterbi puta za prvi niz: 2.651614
Razlika log-izvjesnosti preko svih puteva i uzduz Viterbi puta za drugi niz: 4.575125
```

Slika 6. Rezultati izvršavanja priloženog koda za pod-zadatak 5

**IZVJEŠTAJ:** Usporedite dobivene rezultate s onima iz pod-zadatka 2 gdje je izračunata ukupna log-izvjesnost za sve moguće puteve skrivenih stanja.

**ODGOVOR:** Dobiveni rezultati su manji nego oni iz pod-zadatka 2 gdje su izračunate ukupne log-izvjesnosti za sve moguće puteve skrivenih stanja što je bilo i za očekivati.

**IZVJEŠTAJ:** Što nam govori predznak ovih razlika? Diskutirajte dobivene rezultate u izvještaju. Biste li mogli izračunati i izvjesnosti osmatranja cjelovitih zadanih osmotrenih nizova (u punoj dužini) uzduž svih mogućih pojedinačnih puteva rešetke stanja, kao što je opisano u dokumentu s uputama? Ako ne, zašto ne? Obrazložite.

**ODGOVOR:** Predznak ovih razlika nam govori da su izvjesnost Viterbi puta manja od izvjesnosti svih mogućih puteva što je i za očekivati jer je Viterbijev put jedan od svih mogućih puteva odnosno njegova izvjesnost je sadržana u ukupnoj izvjesnosti svih puteva. Mogli bi izračunati izvjesnosti osmatranja cjelovitih zadanih osmotrenih nizova uzduž svih mogućih puteva pomoću funkcije *dhmm\_logprob\_path* koji smo također koristili u ovom zadatku. Umjesto zadnjeg argumenta funkcije koji je Viterbi puta, trebali bi joj trebali predati određeni put za koji želimo izračunati log-izvjesnost.

### Pod-zadatak 6 - Odredjivanje izvjesnosti osmatranja za skraceni niz i najizvjesniji pojedinačni putevi stanja

(6a) [1 bod] Za prvi osmotreni niz iz pod-zadatka 2 potrebno je odrediti ukupnu izvjesnosti osmatranja skracenog niza, tj. samo za prva cetirosmotrena izlazna simbola o1, o2, o3 i o4. U tu svrhu trebate iskoristiti ranije rjesenje iz treceg pod-zadatka u kojem ste odredili svezjerojatnosti modela, ali za cjelovit niz. Upisite u eksponencijalnom zapisu koliko iznosi izvjesnost (ne log-izvjesnost!) osmatranja prva cetiri izlazna simbola:

Izvjesnost osmatranja prva cetiri izlazna simbola iznosi: **2.332597e-03**

(6b) [1 bod] Ponovno odredite Viterbi put, ali sada za ovu skracenu opservacijsku sekvencu, te izracunajte i u naredno polje upisite koji udio izvjesnosti osmatranja (normirano na 1) se ostvaruje uzduz Viterbi puta u odnosu na sve moguće puteve stanja ovog modela:

Udio izvjesnosti osmatranja uzduz Viterbi puta u odnosu na sve moguće puteve je: **0.627280**

(6c) [1 bod] Upisite nadjeni Viterbi put stanja za prva četiri osmotrena simbola prvog niza:

Viterbi puta stanja za prva 4 izlazna osmotrena simbola je: **2,2,2,2**.

(6d) [1 bod] Izračunajte izvjesnosti osmatranja prva četiri izlazna simbola, ali uzduž svih mogućih pojedinačnih puteva resetke stanja, prema primjeru iz uputa. Koliko ukupno ima ovih pojedinačnih puteva stanja?

Ukupno ima **81** pojedinačnih puteva stanja.

(6e) [1 bod] Temeljem izračunatih izvjesnosti pojedinačnih puteva stanja, odredite koliko puteva od svih njih uopće nisu mogući, pa upisite broj puteva koji imaju nultu izvjesnost osmatranja skraćenog niza:

Broj puteva koji imaju nultu izvjesnost osmatranja skraćenog niza je **57**.

(6f) [1 bod] Sortirajte puteve od najizvjesnijih prema najmanje izvjesnima te u polje upisite koji udio ukupne izvjesnosti osmatranja (normirano na 1) se kumulativno ostvaruje uzduž prvih pet najizvjesnijih puteva ove sortirane liste.

Udio ukupne izvjesnosti osmatranja (normirano na 1) koji se kumulativno ostvaruje uzduž prvih pet najizvjesnijih puteva ove sortirane liste je **0.980125**

*Isječak programskog koda korištenog za rješavanje pod-zadatka 6*

```
% Ispis osmatranja prva četiri izlazna simbola
fprintf('Izvjesnost osmatranja prva četira izlazna simbola iz prvog niza %e\n',
...
    alpha1_sum(4));

% Prvih 4 osmotrena izlazna simbola iz prvog niza - skraćeni niz
data1_1to4 = [3 3 3 4];

% Brojanje slučajeva (broj ćelija u data1)
data1_1to4 = num2cell(data1_1to4, 2);
ncases1to4 = length(data1_1to4);

% Petlja koja obrađuje niz
for m=1:ncases1to4
    % Matrica koja sadrži vjerojatnosti osmatranja skraćenog niza u
    % svim stanjima modela
    obslik_1to4 = multinomial_prob(data1_1to4{m}, obsmat0);
    % Izračun matrice unaprijednih i unazadnih vjerojatnosti, pomoćne
    % vjerojatnosti gama za re-estimaciju HMM modela te logaritamske
    % izvjesnosti osmatranja niza
    [alpha1to4, beta1to4, gamma1to4, ll1to4] = ...
        fwdback(prior0, transmat0, obslik_1to4, 'scaled', 0);
    if ll1to4==-inf
        errors = [errors m];
    end
end
```



```
    loglik = loglik + l1l1to4;
end

% Iskorištavanje funkcije za izračun Viterbijevog puta za skraceni niz
vpath1to4 = viterbi_path(prior0, transmat0, obslik_1to4);
% Iskorištavanje funkcije za izračun log-vjerojatnosti za određeni put (u
% ovom slučaju to je skraćeni niz)
[l1l1to4_v, p1to4] = dhmm_logprob_path(prior0, transmat0, obslik_1to4, vpath1to4);

nums = 1:3;
% Inicijalizacija svih mogućih puteva odnosno sve permutacije brojeva 1-3 u
% nizu duljine 4
[A, B, C, D] = ndgrid(nums, nums, nums, nums);
% Stavljanje svih permutacija u jednu matricu
mpath = [A(:) B(:) C(:) D(:)];

llm=zeros(81,1); % Stupac za log-izvjesnosti
for i=1:81
    % Iskorištavanje funkcije za izračun log-vjerojatnosti za određeni put (u
    % ovom slučaju to je svaki mogući put duljine 4)
    [llm(i), p1to4] = dhmm_logprob_path(prior0, transmat0, obslik_1to4,
mpath(i,:));
end

% Sortiranje log-izvjesnosti svih puteva duljine 4 od najvećeg do najmanjeg
[s1llm, i1llm]=sort(-llm);
% Izračunavanje udjela postotka osmatranja svakog puta, udio postotka
% svakog sljedećeg puta se nadodaje na udjele prethodnih puteva (kumulativna suma)
putevi_vjerojatnost = cumsum(exp(-s1llm))/sum(exp(llm));

% Ispis udjela izvjesnosti Viterbi puta za ovaj skraceni niz u odnosu na
% sve moguće puteve duljine 4
fprintf('Udio izvjesnosti Viterbi puta: %f\n', putevi_vjerojatnost(1));

% Ispis Viterbi puta za prva 4 izlazna simbola prvog niza
fprintf('Viterbi puta za prva 4 izlazna simbola prvog niza: %d,%d,%d,%d.\n', ...
    vpath1to4(1),vpath1to4(2),vpath1to4(3),vpath1to4(4));

% Ispis broja svih mogucih puteva resetka stanja duljine 4
fprintf('Broj svih mogucih puteva resetka stanja duljine 4 je %d\n',
length(mpath));

nedozvoljeni=0;
% Petlja za prebrojavanje puteva koji nisu mogući (to su putevi koji nisu
% ciklički, npr. 1->3->2->1)
for i=1:length(llm)
    if llm(i)==-inf
        nedozvoljeni=nedozvoljeni+1;
    end
end

% Ispis broja nedozvoljenih puteva odnosno puteva koji nisu moguci
fprintf('Broj nedozvoljenih puteva odnosno puteva koji nisu moguci je %d\n',
nedozvoljeni);

% Ispis udjela izvjesnosti prvih pet najizvjesnih puteva u odnosu na
% sve moguće puteve duljine 4
fprintf('Udio izvjesnosti prvih pet najizvjesnih puteva: %f\n',
putevi_vjerojatnost(5));
```

```
% Uzimanje samo prvih put najvjerojatnijih puteva
top_five_indices = illm(1:5);
% U matrici svih puteva pronalazak točno tih pet najvjerojatnijih puteva
top5 = mpath(top_five_indices, :);
% Ispis 5 prije spomenutih puteva
fprintf('To su putevi:\n')
disp(top5);

>> podzadatak6_jakovac
Izvjescnost osmatranja prva cetira izlazna simbola iz prvog niza 2.332597e-03
Udio izvjesnosti Viterbi puta: 0.627280
Viterbi puta za prva 4 izlazna simbola prvog niza: 2,2,2,2.
Broj svih mogucih puteva resetka stanja duljine 4 je 81
Broj nedozvoljenih puteva odnosno puteva koji nisu moguci je 57
Udio izvjesnosti prvih pet najizvjesnih puteva: 0.980125
To su putevi:
    2    2    2    2
    2    2    2    3
    2    2    3    3
    3    3    3    3
    2    3    3    3
```

Slika 7. Rezultati izvršavanja priloženog koda za pod-zadatak 6

**IZVJEŠTAJ:** Objasnite kako ste dobili izvjesnost osmatranja skraćenog niza.

**ODGOVOR:** Izvjesnost osmatranja skraćenog niza sam dobio tako sam iz sumirane matricu unaprijednih vjerojatnosti odnosno *alfa1\_sum* uzeo vrijednost koja ima indeks 4 koji predstavlja vremenski trenutak  $t=4$ . S tim završnim trenutkom je opisan skraćeni niz od 4 izlazna osmotrena simbola.

**IZVJEŠTAJ:** Jeste li za nalaženje ovog Viterbi rješenja skraćenog niza smjeli koristiti rješenje iz pod-zadataka 4 i 5? Obrazložite odgovor.

**ODGOVOR:** Za razliku od podzadatka 6a) gdje sam mogao koristiti rješenje iz prijašnjih podzadataka ovdje nisam mogao koristiti Viterbi put iz pod-zadatka 4 i 5 jer je jedno od obilježja Viterbi puta da se on mora izvršiti do kraja niza i tek se tada može odrediti put. Zbog toga bi rezultat Viterbi puta za skraćeni niz mogao ispasti drugačiji jer se radi o potpuno drugačijem nizu što se tiče duljine kao i završnog simbola. Zaključno, za svaki niz koji osmatramo uvijek moramo napraviti novi algoritam za pronaći Viterbi put, a ne koristiti Viterbi put od nizova koji sadrže niz koji proučavamo.

Temeljem izračunatih izvjesnosti pojedinačnih puteva stanja, odredite koliko puteva od svih njih uopće nisu mogući, tj. u Moodle upišite broj puteva koji imaju nultu izvjesnost osmatranja skraćenog niza.

**IZVJEŠTAJ:** Obrazložite razlog.

**ODGOVOR:** Putevi koji imaju nultu izvjesnost osmatranja skraćenog niza su oni putevi koji nisu ciklički jer je u zadatku zadano kako promatrano samo cikličke nizove što je moguće vidjeti i iz matrice prijelaza u Kojima su neki prijelazi nemogući (vjerojatnost je 0). Tako je npr. put  $2 \rightarrow 1 \rightarrow 3 \rightarrow 2$  nemoguć jer je svaki od ovih prijelaz nemoguć.

Sortirajte puteve od najizvjesnijih prema najmanje izvjesnima te u Moodle upišite koji udio ukupne izvjesnosti osmatranja (normirano na 1) se kumulativno ostvaruje uzduž prvih pet najizvjesnijih puteva ove sortirane liste.

**IZVJEŠTAJ:** Navedite o kojim putevima stanja se radi. Nalazi se među njima i skraćeni Viterbi put? Mogu li različiti putevi stanja imati istu izvjesnost? O čemu to ovisi?

**ODGOVOR:**

To su putevi:

```
2  2  2  2
2  2  2  3
2  2  3  3
3  3  3  3
2  3  3  3
```

Među njima se nalazi i skraćeni Viterbi put što je logično jer je on najizvjesniji skraćeni put. Različiti putevi stanja mogu imati istu izvjesnost no to ovisi o matrici prijelaznih vjerojatnosti odnosno ako su prijelazne vjerojatnosti iste ili slične veća je vjerojatnost da različiti putevi imaju istu izvjesnost. Također, izvjesnost puta ovisi o matrici početnih vjerojatnosti te matrici emisijskih vjerojatnosti. Ako su vjerojatnosti u njima podjednake to je i veća vjerojatnost da na kraju izvjesnost puta biti ista. Zadnje o čemu ovisi izvjesnost puta je i sama duljina puta. Što je dulji put to je manja vjerojatnost da će njegova vjerojatnost biti ista kao neki drugi put iste duljine.

**Pod-zadatak 7 - Generiranje opservacija za zadani model**

(7a) [0 bodova] Generirajte visestruke slučajne nizove osmotrenih izlaznih simbola s  $nex=14$  različitih nizova, pri čemu svaki niz treba bitiduljine  $T=125$  vremenskih uzoraka. Za generiranje podataka koristiti funkciju `dhmm_sample` u skladu s uputama, uz parametre HMM modela iz vašeg individualnog pod-zadatka 1. Sacuvajte ovu matricu opservacija jer će biti intenzivno korištena i u narednim pod-zadacima. Prijepoziva funkcije, svakako resetirajte generator slučajnih brojeva na početnu vrijednost naredbom `rng('default')`. Vaše rješenje će biti provjereno i bodovano u narednom pod-zadatku.

**IZVJEŠTAJ:** Dokumentirajte način generiranja opservacija.

**ODGOVOR:**

*Isječak programskog koda korištenog za rješavanje pod-zadatka 7*

```
rng('default');
% Generiranje visestrukog opservacijskog niza:
T = 125; % duljina svakog niza
nex = 14; % broj opservacijskih nizova
% Inicijalizacija matrice koja sadrži 14 nasumično generiranih nizova duljine 125
data = dhmm_sample(prior0, transmat0, obsmat0, nex, T);
% Ispis matrice
disp(data);
```

```
>> podzadatak7_jakovac
Columns 1 through 18
```

|   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 2 | 5 | 4 | 5 | 2 | 2 | 1 | 1 | 6 | 5 | 5 | 3 | 5 | 3 | 5 | 5 | 5 | 1 |
| 4 | 3 | 6 | 6 | 6 | 5 | 6 | 3 | 2 | 2 | 6 | 4 | 6 | 3 | 3 | 1 | 3 | 3 |
| 5 | 1 | 3 | 4 | 5 | 4 | 5 | 4 | 2 | 1 | 6 | 5 | 3 | 3 | 4 | 5 | 6 | 3 |
| 5 | 6 | 5 | 6 | 1 | 6 | 1 | 2 | 1 | 1 | 1 | 3 | 3 | 6 | 2 | 4 | 4 | 5 |
| 3 | 5 | 5 | 4 | 5 | 2 | 6 | 5 | 5 | 2 | 5 | 5 | 5 | 4 | 3 | 5 | 2 | 1 |

Slika 8. Rezultati izvršavanja priloženog koda za pod-zadatak 7 (prvih 5 nizova u prvih 18 vremenskih trenutaka)

### Pod-zadatak 8 - Odredjivanje dugotrajne statistike osmotrenih simbola i usporedba s njihovim teorijskim ocekivanjima

(8a) [1 bod] Za nizove koji su generirani u pod-zadatku 7, potrebno je eksperimentalno odrediti vjerojatnosti osmatranja svih izlaznih simbolakoristenjem slicnih primjera iz uputa. Za prvu osmotrenu sekvencu iz proslog pod-zadatka upisite broj osmatranja svakog izlaznog simbola, od 1 do 6, kojeg cete naci funkcijom hist:

Broj osmatranja izlaznog simbola 1 za prvu sekvencu: **15**,  
 Broj osmatranja izlaznog simbola 2 za prvu sekvencu: **15**,  
 Broj osmatranja izlaznog simbola 3 za prvu sekvencu: **36**,  
 Broj osmatranja izlaznog simbola 1 za prvu sekvencu: **13**,  
 Broj osmatranja izlaznog simbola 1 za prvu sekvencu: **33**,  
 Broj osmatranja izlaznog simbola 1 za prvu sekvencu: **13**.

(8b) [1 bod] Potrebno je odrediti teorijska ocekivanja dugotrajnih vjerojatnosti osmatranja izlaznih simbola. Pri tome, prvo odredite stacionarnu distribuciju stanja ( $\pi_{\text{stac}}$ ) uzastopnim mnozenjem zadane prijelazne matrice  $A$  same sa sobom i to  $T$  puta, te zatim temeljem ovedugotrajne statistike vjerojatnosti stanja modela i matrice izlaznih vjerojatnosti osmatranja  $B$ , odredite ocekivane stacionarne vjerojatnostiosmatranja svih izlaznih simbola (1 do 6), a sve sukladno primjeru iz uputa. Za provjeru tocnosti vasih rjesenja, upisite dugotrajnu vjerojatnost stanja 1 modela,  $p(q=1)$  kao i dugotrajnu vjerojatnost osmatranja izlaznog simbola 4,  $p(o=4)$  :

Dugotrajna vjerojatnost stanje modela 1 je **0.333333**  
 Dugotrajna vjerojatnost osmatranja izlaznog simbola 4 je **0.116667**

(8c) [1 bod] Odredite empirijske dugotrajne vjerojatnosti osmatranja simbola (pomocu funkcije hist) i to usrednjavanjem broja pojava simbolapreko svih nex eksperimenata, te ih usporedite s upravo izracunatim ocekivanim dugotrajnim statistikama izlaznih simbola. Upisite najveciapsolutni iznos razlike izmedju empirijskih i teorijskih vjerojatnosti izlaznih simbola maksimiziran preko svih 6 izlaznih simbola :

Maksimalna razlike između statistike i empirijskih vjerojatnost za neki od izlaznih simbola je **0.016143**

*Isječak programskog koda korištenog za rješavanje pod-zadatka 8*

```
% Prebrojavanje simbola u svakoj sekvenci
hm=hist(data',[1 2 3 4 5 6]);

% Ispis osmatranja izlaznih simbola za prvu sekvencu
fprintf('Broj osmatranja izlaznih simbola za prvu sekvencu, redom od 1 do 6: \n');
disp(hm(:,1));

% Određivanje stacionarnu distribuciju stanja (pi_stac) uzastopnim množenjem
% zadane prijelazne matrice A same sa sobom i to T puta
pi_stac=transmat0; for i=1:T, pi_stac=pi_stac*transmat0; end;

% Ispis dugotrajne vjerojatnosti stanja modela 1
fprintf('Dugotrajna vjerojatnost stanje modela 1 je %f\n', pi_stac(1,1))

% Određivanje dugotrajne statistike izlaznih simbola odnosno njihove
% vjerojatnosti da se dogode kroz dulje vrijeme
dugotrajna_statistika = pi_stac(1,:)*obsmat0;

% Ispis dugotrajne vjerojatnosti osmatranja izlaznog simbola 4
fprintf('Dugotrajna vjerojatnost osmatranja izlaznog simbola 4 je %f\n',
dugotrajna_statistika(4));

% Empirijske vjerojatnosti koje smo dobili prebrojavanje simbola odnosno
% njihova vjerojatnost da se dogode u našim nasumično odabranim slučajevima
empirijska = mean(hm')/T;

% Izračun razlike između statistike i empirijskih vjerojatnost za svaki
% izlazni simbol
razlike = abs(dugotrajna_statistika - empirijska);

% Maksimalna razlika između statistike i empirijskih vjerojatnost za neki
% od izlaznih simbola
max_razlika = max(razlike);

% Ispis maksimalne razlike između statistike i empirijskih vjerojatnost za neki
% od izlaznih simbola
fprintf(['Maksimalna razlike između statistike i empirijskih vjerojatnost za ' ...
'neki od izlaznih simbola je %f\n'], max_razlika)

>> podzadatak8_jakovac
Broj osmatranja izlaznih simbola za prvu sekvencu, redom od 1 do 6:
    15
    15
    36
    13
    33
    13

Dugotrajna vjerojatnost stanje modela 1 je 0.333333
Dugotrajna vjerojatnost osmatranja izlaznog simbola 4 je 0.116667
Maksimalna razlike između statistike i empirijskih vjerojatnost za neki od izlaznih simbola je 0.016143
```

Slika 9. Rezultati izvršavanja priloženog koda za pod-zadatak 8

**IZVJEŠTAJ:** Diskutirajte dobivene dugotrajne vjerojatnosti pojedinih stanja, odnosno izlaznih simbola. Kako bi izgledao degenerirani HMM model s jednakim dugotrajnim statistikama opservacija izlaznih simbola?

**ODGOVOR:** Sve dobivene vjerojatnosti pojedinih stanja su iste što je očekivano pošto se radi o cikličkom kretanju stanja, dok se to ne može reći za vjerojatnosti izlaznih simbola koje variraju što je i za očekivati jer se u svakom stanju određeni broj pojavljuje u polovici slučaja dok drugim brojevima nije određena točna vjerojatnost. Degenerirani HMM model bi izgledao tako da matrica observacijskih simbola za svako stanje imaju uniformnu razdiobu.

U konačnici, odredite empirijske dugotrajne vjerojatnosti osmatranja simbola (pomoću funkcije hist) i to usrednjavanjem broja pojava preko svih *nex* eksperimenata.

**IZVJEŠTAJ:** Usporedite ih s upravo izračunatim očekivanim dugotrajnim statistikama izlaznih simbola.

**ODGOVOR:** Emisijske dugotrajne vjerojatnosti su slične dugotrajno statistike što je bilo i za očekivati jer se ipak proveo eksperiment na velikom vremenskom trenutku. Kako bi bilo još sličniji mogli bi dodati još par nizova da ih bude više od 14 te bi s time dobili manji razliku između njihovih vjerojatnosti.

### Pod-zadatak 9 - Izracun log-izvjesnosti osmatranja pojedinacnih generiranih opservacija temeljem zadanog modela

(9a) [1 bod] Za svaki od slučajnih nizova koji su generirani u pod-zadatku 7 potrebno je izracunati log-izvjesnost osmatranja uz zadani model, tj. uz isti model koji je koristen za generiranje ovih osmatranja. Nakon toga izracunajte najveću, najmanju i srednju vrijednost log-izvjesnost usrednjenu preko svih *nex* osmotrenih nizova, te upisite dobivene rezultate u naredna tri polja (max, min i mean):

Maksimalna vrijednost: **-195.180987**

Minimalna vrijednost: **-217.788944**

Srednja vrijednost: **-204.615475**

*Isječak programskog koda korištenog za rješavanje pod-zadatka 9*

```
% Inicijalizacija polja u kojemu će biti pohranjene log-izvjesnost svih 14
% nasumično odabranih nizova
ll_data = [];

for i=1:nex
    for m=1:1
        % Uzimanje pojedinačnog niza
        data_row = data(i, :);
        % Pretvaranje niza u ćeliju
        data_row = num2cell(data_row, 2);
        % Matrica koja sadrži vjerojatnosti osmatranja pojedinačnog niza u
        % svim stanjima modela
        obslik = multinomial_prob(data_row{m}, obsmat0);
        % Izračun matrice unaprijednih i unazadnih vjerojatnosti, pomoćne
        % vjerojatnosti gama za re-estimaciju HMM modela te logaritamske
        % izvjesnosti osmatranja niza
        [alpha, beta, gamma, ll] = ...
            fwdback(prior0, transmat0, obslik, 'scaled', 0);
        % Dodavanje pojedinačnih log-izvjesnosti u polje
        ll_data(end+1) = ll;
        if ll== -inf
            errors = [errors m];
        end
    end
end
```

```
        loglik = loglik + ll;
    end
end

% Pronalazak srednje, minimalne i maksimalne vrijednost za log-izvjesnost
% 14 nasumičnih nizova
sr_vr_data = mean(ll_data);
min_data = min(ll_data);
max_data = max(ll_data);

% Ispis navedenih vrijednosti
fprintf(['Maksimalna vrijednost: %f\nMinimalna vrijednost: %f\nSrednja vrijednost: '
        ...
        '%f\n'], max_data, min_data, sr_vr_data);

>> podzadatak9_jakovac
Maksimalna vrijednost: -195.180987
Minimalna vrijednost: -217.788944
Srednja vrijednost: -204.615475
```

Slika 10. Rezultati izvršavanja priloženog koda za pod-zadatak 9

**IZVJEŠTAJ:** Zašto se izvjesnosti pojedinih nizova razlikuju?

**ODGOVOR:** Kako su nizovi nasumično odabrani tako se u nekim nizovima našao podniz koji je vjerojatniji i tim se log-izvjesnost povećava. Isto tako su mogući neki podnizovi koji su jako malo vjerojatniji te se tako i ukupna vjerojatnost smanjuje. Uzevši u obzir i veliki ukupni vremenski trenutak logično je da će se izvjesnosti pojedinih nizova razlikovati.

#### **Pod-zadatak 10 - Provedite postupak treniranja parametara HMM modela**

(10a) [2 boda] Temeljem svih nizova osmatranja koji su generirani u pod-zadatku 7, potrebno je izračunati dva nova HMM modela primjenom funkcije `dhmm_em`. **Vazno:** u oba slučaja ograničite broj iteracija EM postupka na najviše 200, a prag relativne promjene izvjesnosti u odnosu na proslu iteraciju za završetak postupka postavite na  $1E-6$ .

Za prvi HMM model inicijalizacija parametara modela za početnu iteraciju EM postupka treba biti potpuno slučajna (prema uputama), uz prethodno **resetiranje** generatora pseudo-slučajnih brojeva na početnu vrijednost. Za drugi HMM model za inicijalizaciju EM postupka iskoristite parametre zadanog modela. Točnost vasesg izračuna parametara modela verificirat će se u narednom pod-zadatku.

Za brzu provjeru upišite broj iteracija koji je bio potreban za estimaciju parametara HMM modela EM postupkom za oba modela (prvi i drugi):

Broj iteracija koji je bio potreban za estimaciju parametra za prvi model je **66**, a za drugi je **13**.

*Isječak programskog koda korištenog za rješavanje pod-zadatka 10*

```
% Resetiranje generatora pseudo-slučajnih brojeva na početnu vrijednost
rng('default');
```

```
% Inicijalizacija potpuno slučajnih parametara modela
% Iskorišteni varijable Q - broj stanja i O - broj izlaznih modela
prior1 = normalise(rand(Q,1)); % Matrica početnih vjerojatnosti
transmat1 = mk_stochastic(rand(Q,Q)); % Matrica prijelaznih vjerojatnosti
obsmat1 = mk_stochastic(rand(Q,O)); % Matrica emisijskih vjerojatnosti

% Učenje parametara modela temeljeno na algoritmu maksimizacije očekivanja
% za model s potpuno slučajnih parametrima
% Ispis iteracija za prvi HMM model
fprintf('Ispis iteracija za prvi HMM model sa slučajnim parametrima:\n')
[LL2, prior2, transmat2, obsmat2] = dhmm_em(data, prior1, transmat1, obsmat1,
'max_iter', 200, 'thresh', 1E-6);

% Ispis iteracija za prvi HMM model
fprintf('\nIspis iteracija za drugi HMM model sa već zadanim parametrima:\n')

% Učenje parametara modela temeljeno na algoritmu maksimizacije očekivanja
% za model s već zadanim parametrima
[LL3, prior3, transmat3, obsmat3] = dhmm_em(data, prior0, transmat0, obsmat0,
'max_iter', 200, 'thresh', 1E-6);

% Za oba učenja je broj iteracija EM postupka na najviše 200, a prag
% relativne promjene izvjesnosti u odnosu na proslu iteraciju za zavrsetak
% postupka je na 1E-6
```

```
>> podzadatak10_jakovac
Ispis iteracija za prvi HMM model sa slučajnim parametrima:
iteration 1, loglik = -3079.062495
iteration 2, loglik = -3052.791427
iteration 3, loglik = -3052.120512
iteration 4, loglik = -3051.466384
iteration 5, loglik = -3050.796590
... (nisu prikazane sve iteracije za prvi HMM model radi preglednosti)
iteration 62, loglik = -2852.833554
iteration 63, loglik = -2852.829293
iteration 64, loglik = -2852.825701
iteration 65, loglik = -2852.822654
iteration 66, loglik = -2852.820051

Ispis iteracija za drugi HMM model sa već zadanim parametrima:
iteration 1, loglik = -2864.616653
iteration 2, loglik = -2855.751947
iteration 3, loglik = -2854.309082
iteration 4, loglik = -2853.785839
iteration 5, loglik = -2853.536700
iteration 6, loglik = -2853.404788
iteration 7, loglik = -2853.332054
iteration 8, loglik = -2853.291204
iteration 9, loglik = -2853.268028
iteration 10, loglik = -2853.254794
iteration 11, loglik = -2853.247203
iteration 12, loglik = -2853.242835
iteration 13, loglik = -2853.240315
```

Slika 11. i Slika 12. Rezultati izvršavanja priloženog koda za pod-zadatak 10



**IZVJEŠTAJ:** Obrazložite razliku broja iteracija.

**ODGOVOR:** Razlika u broju iteracija između dva modela proizlazi iz činjenice da je drugi model počeo s "boljim" ili "informiranijim" početnim procjenama. To dovodi do brže konvergencije u usporedbi s prvim modelom, koji počinje s potpuno slučajnim i manje informativnim početnim procjenama. Ova situacija ističe važnost dobre inicijalizacije parametara u EM postupku, posebno u kompleksnim modelima kao što su HMM-ovi.

### **Pod-zadatak 11 - Usporedna evaluacija zadanog modela, slučajnog modela i treniranih modela na istim podacima koji su korišteni za trening**

(11a) [2 boda] Potrebno je usporediti uspješnost modeliranja opservacijskih nizova generiranih u pod-zadatku 7 sa svim raspoloživim HMM modelima, izracunom log-izvjesnosti osmatranja svih generiranih nizova funkcijom `dhmm_logprob`. Kao "los" model za usporedbu, potrebno je koristiti HMM model s potpuno slučajnim parametrima, koji je korišten za inicijalizaciju prvog od dva nova "optimalna" HMM modela u proslom pod-zadatku (**Vazno:**, ... pazite da su parametri ovog slučajnog modela uistinu generirani odmah nakon inicijalizacije generatora pseudo-slučajnih brojeva).

U četiri polja upisite dobivene log-izvjesnosti osmatranja ovim redom: za zadani model, za "losi" slučajni model, za prvi novi HMM model sa slučajnom inicijalizacijom i konacno za drugi novi HMM model sa zadanom inicijalizacijom:

Log-izvjenost za zadani model: **-2864.616653**

Log-izvjenost za "los" model: **-3079.062495**

Log-izvjenost za HMM1 model: **-2852.817814**

Log-izvjenost za HMM2 model: **-2853.238858**

*Isječak programskog koda korištenog za rješavanje pod-zadatka 11*

```
% Izračuni log-izvjenosti kako bi usporedili uspješnost modeliranja
% opservacijskih nizova generiranih u pod-zadatku 7 sa svim raspoloživim
% HMM modelima

% Log-izvjesnost za zadani model
ll_zadani_model=dhmm_logprob(data, prior0, transmat0, obsmat0);
% Ispis za zadani model
fprintf('Log-izvjenost za zadani model: %f\n', ll_zadani_model);

% Log-izvjesnost za "los" model
ll_los_model=dhmm_logprob(data, prior1, transmat1, obsmat1);
% Ispis za "los" model
fprintf('Log-izvjenost za "los" model: %f\n', ll_los_model);

% Log-izvjesnost za HMM1 model (proizlazi iz loseg modela)
ll_HMM1_model=dhmm_logprob(data, prior2, transmat2, obsmat2);
% Ispis za HMM1 model
fprintf('Log-izvjenost za HMM1 model: %f\n', ll_HMM1_model);

% Log-izvjesnost za HMM2 model (proizlazi iz zadanog modela)
ll_HMM2_model=dhmm_logprob(data, prior3, transmat3, obsmat3);
```

```
% Ispis za HMM2 model
fprintf('Log-izvjenost za HMM2 model: %f\n', ll_HMM2_model);

>> podzadatak11_jakovac
Log-izvjenost za zadani model: -2864.616653
Log-izvjenost za "los" model: -3079.062495
Log-izvjenost za HMM1 model: -2852.817814
Log-izvjenost za HMM2 model: -2853.238858
```

Slika 13. Rezultati izvršavanja priloženog koda za pod-zadatak 11

**IZVJEŠTAJ:** Objasnite koji je odnos log-izvjesnosti pojedinih nizova iz pod-zadataka 9 s upravo određenom ukupnom log-izvjesnosti svih nizova za zadani model. Diskutirajte dobivene rezultate novih modela u usporedbi s log-izvjesnosti osmatranja istih nizova za zadani model. Prikažite i usporedite estimirane vrijednosti parametara novih treniranih modela (matrice A, B, pi) sa zadanim modelom. Kako objašnjavate razlike parametara ovih modela? Je li provjera estimiranog modela na istim podacima koji su korišteni za treniranje primjeren postupak? Kako bi se trebao provesti pravi postupak treniranja i validacije modela?

*Isječak koda kojim možemo provesti određenu usporedbu parametara zadanog modela i modela treniranog na njemu (kod je nastavak na prijašnji kod korišten u ovom pod-zadatku)*

```
% Ispis parametara novog modela treniranog na zadanom modelu
fprintf('Matrica A - trenirani model (prijelazne vjerojatnosti):\n')
disp(transmat3)
fprintf('Matrica B - trenirani model (emisijske vjerojatnosti):\n')
disp(obsmat3)
fprintf('Matrica pi - trenirani model (početne vjerojatnosti):\n')
disp(prior3)

Matrica A - trenirani model (prijelazne vjerojatnosti):
    0.9011    0.0989         0
         0    0.8863    0.1137
    0.1263         0    0.8737

Matrica B - trenirani model (emisijske vjerojatnosti):
    0.4645    0.0783    0.0501    0.1445    0.1124    0.1502
    0.1103    0.0754    0.4883    0.0638    0.0527    0.2096
    0.0274    0.1310    0.0994    0.1442    0.5408    0.0572

Matrica pi - trenirani model (početne vjerojatnosti):
    0.2786
    0.1378
    0.5836
```

Slika 14. Rezultati izvršavanja priloženog koda za pod-zadatak 11

**ODGOVOR:** Uzevši srednju vrijednost log-izvjesnosti za nizove iz pod-zadatka 9 koja poprima vrijednost od  $\text{mean} = -204.615475$  te broj nizova  $\text{nex} = 14$ , njihovim množenjem dobivamo upravo ukupnu log-izvjesnost evaluacije za zadani model  $(-2864.6167)$  što je i očekivano jer model još nije bio uopće treniran te bi log-izvjesnosti trebale biti jednake. Novi modeli u usporedbi s zadanim modelom imaju veću log-izvjesnost odnosno veća je vjerojatnost njihovog pojavljivanja sa njihovim treniranim parametrima. To je također bilo za očekivati pošto smo model istrenirali na podacima koji su se koristili za zadani model kroz veliki broj iteracija. Iako se ne vidi prevelika razlika u njihovim log-izvjesnostima svejedno smo treningom uspjeli dobiti “bolje” parametar modela.

Prikazani parametri treniranog novog modela ovise o podatku na kojemu se trenirao model odnosno pomoću njegovih podataka parametri se treniraju i tako se napravi razlika između njih i parametara zadanog modela koji nije treniran. Međutim, vidimo da se njihovi parametri ne razlikuju previše što znači da nije bio potreban trening u puno iteracija kao što je bilo potrebno kod treninga na slučajnom modelu. Provjera estimiranog modela na istim podacima koji su korišteni za treniranje nije primjeren postupak jer će na evaluaciji na istim podacima model biti pristran i pokazat će se velika uspješnost treninga iako je moguće da na nekom drugom podatku je puno manja uspješnost. Evaluacija modela bi se uvijek treba vršiti na podacima na kojima model nije treniran kako model ne bi iskazao pristranost podacima na kojima je treniran. Često je skup podataka na kojima se vrši evaluacija znatno manji dok iako je skup podataka veći, ne smije biti prevelik kako ne bi “overfittali” model odnosno pretrenirali ga.